

Asistente conversacional

Propuesta técnica y de producto · Plataforma AME · 27/07/2026

Este documento describe la incorporación de un asistente conversacional a la app mobile de clientas: qué problema resuelve, cómo se construiría sobre lo que la plataforma ya tiene, qué límites debe respetar y en qué momento del plan conviene encararlo. La conclusión corta: **es viable y el proyecto es un sustrato inusualmente bueno**, porque la capa más costosa de este tipo de sistemas —el acceso a datos reales y seguros— ya está construida y probada.

Qué resuelve

El centro responde las mismas preguntas una y otra vez: qué es cada tratamiento, si duele, cuánto dura, qué producto sirve para determinado tipo de piel, cuándo es el próximo turno. Hoy eso ocupa tiempo del staff por canales dispersos. Un asistente dentro de la app absorbe ese volumen y, más importante, **convierte**: puede llevar de una consulta a una reserva o a una recompra sin fricción intermedia.

Alineación con el negocio: los dos problemas declarados del centro son la adquisición de clientas y la baja conversión a servicios, con la venta de productos como fuente principal de ingresos. El asistente ataca el segundo y el tercero de forma directa.

1. Lo que ya está construido

La diferencia entre este proyecto y un desarrollo desde cero es que **los datos no son documentos: son registros vivos** —servicios, productos, turnos, la rutina de cada clienta, la disponibilidad—. Eso no se resuelve con búsqueda de texto sino con acceso directo y controlado, y esa capa ya existe: los endpoints de la API de clientes se traducen casi uno a uno en las herramientas del asistente.

Herramienta del asistente	Endpoint existente	Ejemplo de consulta
Buscar tratamientos	Catálogo público y reservables	"¿Qué tratamientos hay para el rostro?"
Mis turnos	Listado de turnos del cliente	"¿Cuándo tengo turno?"
Ver disponibilidad	Disponibilidad por servicio y fecha	"¿Hay lugar el martes a la tarde?"
Reservar turno	Alta de turno con validación completa	"Sacame turno para el jueves"
Mi rutina	Rutina activa y plan de tratamiento	"¿Qué me toca de noche?"

Cada una de esas herramientas ya tiene resuelto lo difícil: autenticación propia de clientas, alcance por vinculación, prevención de doble reserva, política de días y anticipación, y aislamiento entre centros. El asistente no reimplementa nada de eso: lo consume.

2. Arquitectura

La propuesta se organiza en cuatro capas. No todas pesan igual, y ordenarlas mal es el error más común en este tipo de proyectos.

2.1 Modelo: instrucciones y uso de herramientas

Es el 80% del valor y por donde se empieza. El asistente recibe un conjunto acotado de herramientas y decide cuál usar según lo que se le pregunta. El ciclo consulta → herramienta → respuesta lo maneja el SDK oficial; el trabajo propio está en diseñar bien las herramientas y las instrucciones.

Invariante de seguridad: el asistente corre en el servidor con la identidad de la clienta autenticada. Las herramientas resuelven a qué ficha acceden a partir de esa sesión, **nunca de un identificador propuesto por el modelo**. Es la misma regla que ya rige toda la API de clientes.

2.2 Recuperación de contenido

Aplica solo al contenido en prosa: fichas de tratamiento, descripciones de producto, preguntas frecuentes, cuidados. **Hoy ese contenido no existe** —se carga en las etapas previas del plan— y cuando exista, no implica necesariamente infraestructura nueva. La progresión correcta es incremental:

Escalón	Cuándo	Costo de infraestructura
Todo el contenido en el contexto	Corpus chico (decenas de páginas). Punto de partida.	Ninguno
Herramienta que trae la ficha puntual	El modelo pide un tratamiento, se le da solo esa ficha.	Ninguno
Búsqueda de texto de PostgreSQL	Preguntas frecuentes, búsqueda por palabra clave.	Ninguno (ya instalado)
Búsqueda semántica con pgvector	Cuando fallan las paráfrasis ("manchas" / "hiperpigmentación").	Extensión sobre la base actual
Base vectorial dedicada	A la escala de un centro, prácticamente nunca.	Servicio nuevo

Conviene medir antes de decidir: con una ventana de contexto de un millón de tokens y caché de instrucciones, el catálogo completo de un centro entra sin problema y se lee a una fracción del costo. El salto al escalón siguiente se justifica por calidad de respuesta —demasiado contenido irrelevante degrada la precisión— antes que por capacidad.

2.3 Ciclo de conversación

Un único ciclo acotado con estado alcanza. El caso que sí requiere varios pasos encadenados es la reserva conversacional: *"quiero turno para limpieza la semana que viene a la tarde"* obliga a consultar disponibilidad, proponer opciones y confirmar. Arquitecturas de múltiples agentes coordinados serían sobredimensionadas para este alcance.

2.4 Evaluación

Es la capa que decide si el sistema es publicable, y la que más se subestima. Consiste en un conjunto de casos de prueba con respuesta esperada, ejecutado como parte de la suite de tests, más un evaluador automático para las respuestas abiertas. Cubre dos cosas distintas:

- **Que responda bien** lo que tiene que responder: precios, horarios, disponibilidad, datos propios de la clienta.
- **Que se niegue** cuando tiene que negarse: toda consulta clínica (ver sección 3).

El conjunto de casos no hay que inventarlo: el historial de consultas del centro por WhatsApp e Instagram contiene las preguntas reales que hace la gente. Recolectar unas cincuenta de ahí es el primer paso, cuesta nada, y de paso indica si el asistente hace falta o si esas dudas se resuelven con una buena ficha de tratamiento.

2.5 Observabilidad y costo

Cada interacción se registra con tokens de entrada y salida, latencia, herramientas invocadas y costo calculado. Con eso se responde "¿cuánto sale?" y "¿qué se está preguntando?" con datos, no con impresiones. Se complementa con un tope de uso diario por clienta para acotar el gasto ante un uso anómalo.

3.1 El asistente no da indicaciones clínicas

Es la decisión de diseño más importante del proyecto. Las clientas van a preguntar si pueden hacerse un tratamiento estando embarazadas, si les sirve teniendo rosácea, o si un producto se mezcla con el ácido que ya usan. **Un sistema automático respondiendo eso con el nombre del centro encima es un riesgo real**, no teórico.

La regla es explícita: ante cualquier consulta clínica, el asistente deriva a la profesional. No se resuelve mejorando la información disponible —aunque la ficha tenga las contraindicaciones cargadas, la respuesta correcta sigue siendo derivar—. Es una política, y por eso se verifica con casos de prueba específicos que fallan el deploy si el comportamiento se rompe.

3.2 Aislamiento de datos

La plataforma es multi-inquilino: cada centro ve solo lo suyo. El asistente es una superficie nueva sobre esos mismos datos y debe respetar la misma frontera, con el agravante de que es más difícil de auditar a simple vista. De ahí que el alcance se resuelva siempre en el servidor y nunca a partir de lo que el modelo proponga.

3.3 Contenido como prerequisite

El asistente no puede responder mejor de lo que sabe. Sin fichas de tratamiento ni descripciones de producto cargadas, queda limitado a nombre, duración, precio y a los datos propios de la clienta. Por eso el trabajo de contenido —que ya está planificado— es condición previa, no una mejora posterior.

4. Decisiones técnicas

El backend es Python con Django, así que la integración usa el SDK oficial de Anthropic para Python. Las decisiones relevantes, y sobre todo lo que se decide **no** usar:

Decisión	Elegido	Motivo
Acceso al modelo	SDK oficial, invocación directa	El ciclo de herramientas viene resuelto por el SDK. Un framework intermedio agrega abstracción sobre pocas líneas de código y oculta lo que conviene entender.
Modelo	Se elige por ruta	Un modelo económico alcanza para consultas de catálogo; uno de mayor capacidad se reserva para las conversaciones complejas. Elegir bien es parte del trabajo.
Respuesta en pantalla	Envío incremental	La respuesta aparece a medida que se genera. Sin esto la espera se percibe como que la app se colgó.
Caché de instrucciones	Activa desde el inicio	El texto fijo y el catálogo se cachean y se releen a una fracción del costo. Es la palanca de ahorro más grande.
Evaluación	Suite propia sobre pytest	A esta escala, un conjunto de casos propio es más simple y más transparente que adoptar una herramienta externa.
Base vectorial	No, por ahora	Ver la progresión de la sección 2.2. Cuando haga falta, es una extensión de la base que ya corre.

4.1 Orden de magnitud del costo

Estimación con supuestos explícitos: instrucciones y catálogo cacheados en torno a quince mil tokens, una conversación de unos pocos intercambios y una respuesta final de unos cientos de tokens.

- Con un modelo económico: **del orden de medio centavo de dólar por conversación.**
- Con un modelo de alta capacidad: **unos pocos centavos por conversación.**

A volúmenes de un centro de estética, el costo del modelo no es el factor limitante. Aun así se instrumenta desde el principio: la cifra hay que medirla, no suponerla, y el tope diario por clienta acota cualquier uso anómalo.

5. Alcance de la primera versión

Deliberadamente angosta. El objetivo de la primera versión no es cubrir todo, sino validar que las clientas efectivamente la usan y que el comportamiento es seguro.

Incluye

- Consultas sobre el catálogo: qué tratamientos hay, duración, precio, en qué días se pueden reservar.
- Consultas sobre datos propios: próximos turnos, historial, rutina de cuidado.
- Reserva de turno asistida, con confirmación explícita antes de crear nada.
- Negativa y derivación ante cualquier consulta clínica.
- Registro completo de cada interacción con su costo.
- Conjunto de casos de evaluación construido a partir de consultas reales del centro.

No incluye

- Búsqueda semántica sobre contenido en prosa (llega cuando el contenido exista y lo justifique).
- Cancelación o reprogramación por el asistente: son acciones destructivas y quedan en la interfaz, donde la confirmación es inequívoca.
- Recomendación de tratamientos según características de la piel: es consejo clínico.
- Cualquier operación de pago.

Cómo se mide si funcionó

Tres indicadores, definidos antes de construir:

- **Uso:** qué proporción de clientas activas lo abre, y cuántas vuelven a usarlo.
- **Conversión:** cuántas reservas se originan en una conversación con el asistente.
- **Seguridad:** proporción de consultas clínicas correctamente derivadas, medida sobre el conjunto de casos y sobre conversaciones reales revisadas a mano.

6. Riesgos

Riesgo	Mitigación
El asistente responde una consulta clínica	Instrucción explícita de derivación, casos de prueba adversarios que frenan el deploy, y revisión manual de conversaciones durante las primeras semanas.
Afirma datos incorrectos (precios, horarios)	Los datos salen siempre de herramientas contra la base, nunca de la memoria del modelo. Lo que no puede consultar, no lo responde.
Alguien intenta acceder a datos de otra clienta	El alcance se resuelve en el servidor a partir de la sesión autenticada. El modelo no puede proponer a qué ficha acceder.
Costo mayor al esperado	Caché de instrucciones, elección de modelo por ruta, registro por interacción y tope diario por clienta.
Nadie lo usa	Es el riesgo más probable y por eso la primera versión es chica. Se mide uso antes de invertir en las capas siguientes.

7. Ubicación en el plan

El asistente se apoya en trabajo que ya está planificado y que hay que hacer de todos modos. Esta es su posición respecto del resto:

Antes	Por qué es prerequisite
Ficha de tratamiento con contenido	Sin descripción, beneficios y cuidados cargados, el asistente no tiene de dónde responder más allá de nombre, duración y precio.
Descripciones de producto	Mismo motivo, del lado del catálogo de productos.
Almacenamiento de imágenes en la nube	Necesario para que las fichas tengan foto y sobrevivan a un despliegue.
Notificaciones push	No es estrictamente necesario, pero comparte la infraestructura de comunicación con la clienta y conviene tenerlo resuelto antes.

Con esos puntos cubiertos, el asistente pasa de ser una funcionalidad aislada a ser la capa que conecta lo que ya existe: catálogo, turnos, rutina y recompra, en una sola conversación. Ese es el argumento para ubicarlo al final y no antes: **no es un desvío del plan, es lo que lo corona.**

Primer paso, que no requiere escribir código

Recolectar unas cincuenta consultas reales del historial de WhatsApp e Instagram del centro. Sirve para tres cosas a la vez: es el conjunto de evaluación, indica qué herramientas hacen falta de verdad, y revela si esas dudas se resuelven con una buena ficha de tratamiento en lugar de un asistente. Es la forma más barata de decidir si este proyecto vale la pena antes de invertir en él.